AI Safety Challenge

Çıktı: AI Fail-Safe Decision

Ad Soyad Mustafa Önler | Grup Gece-B | Tarih

Kavram — Prediction ≠ Safety: Yapay zekâ bir karar üretir; güvenliği garanti eden mimari YZ'nin **dışında** tanımlanmalıdır. (Araçlar: fail-safe, human override, monitoring, confidence threshold, fallback).

Senaryo Uyarlaması: Baykal Abkant Pres makinesine büküm alanını izleyen, sac yerleşimini ve operatörün elini tanıyan "YZ Destekli Akıllı Kamera" eklenmesi planlanıyor.

Kamera → YZ Modeli (El mi/Sac mı?) → OK / STOP → Pres İniş İzni → Üst Çene Hızı

Görev — üç başarısızlıkta güvenli davranış

1. **Model yanlış sınıflandırdı:** Kusurlu parçaya OK verdi. (YZ, operatörün elini "sac levha" zannedip üst çenenin inmesine OK verdi). Sistem ne yapmalı? İkinci kontrol / insan onayı var mı?

   Cevap: YZ'nin kararı hiçbir zaman donanımsal emniyetin yerini alamaz. YZ modeli yanlışlıkla "OK" onayı verse bile, makinenin asıl güvenlik katmanı olan **fiziksel ışık bariyeri (lazer koruma)** eli algıladığı an Safety PLC devreye girip YZ'nin kararını ezmeli ve hidrolik valfleri kesmelidir (STO). Ayrıca nihai büküm onayı her zaman operatörün ayak pedalına basmasına (insan onayı) bağlı olmalıdır.

2. **Girdi manipüle edildi:** Kamera verisi bozuk/sahte. (Kamera lensi yağlandı, üzeri kapatıldı veya sensöre lazer tutuldu). Nasıl fark edilir? Şüpheli girdide ne yapılır?

   Cevap: Kameradan gelen görüntüde ani kararma, kontrast kaybı (entropy değişimi) veya sinyal donması "monitoring" (izleme) sistemiyle tespit edilir. Şüpheli bir girdi (veya siber müdahale kaynaklı sahte frame) algılandığında sistem anında "Safe State" (güvenli durum) moduna geçerek üst çeneyi kilitler. Üretime devam edebilmek için operatörün merceği temizleyip makineyi fiziksel olarak resetlemesi (fallback) gerekir.

3. **Confidence düştü:** Model "emin değilim" diyor. Eşik ne olmalı? Altında: dur / insana sor / fallback?

   Cevap: Ölümcül ezilme riski taşıyan bir abkant preste emniyet söz konusu olduğunda güven eşiği (Confidence Threshold) %99.9 olmalıdır. Model, kalıptaki cismin sac mı yoksa el mi olduğundan tam emin olamazsa (örneğin %85 eminse), makine hidrolik hareketi anında **durdurur**. HMI (CNC ekranı) üzerinde "Tanımsız Cisim Uyarı" pop-up'ı çıkar ve sistem **insana sor** (human in the loop) moduna geçer. Operatör görsel olarak alanı kontrol edip çift el butonuyla onay verene kadar makine kilitli kalır.

Karar tablosu — AI Fail-Safe Decision

Başarısızlık	Tanımladığınız güvenli davranış (hangi kavramla?)
Model yanlış sınıflandırdı	YZ kararını ezen fiziksel lazer bariyerin (Safety PLC) makineyi anında durdurması. **(Kavram: Fail-Safe & Human Override)**
Girdi manipüle edildi	Görüntü anomalisi/veri kaybı algılandığı anda üst çenenin hidrolik kilitlenmesi. **(Kavram: Monitoring & Fallback)**
Confidence düştü	Eşik (%99.9) altına düşüldüğünde makinenin durup CNC ekranından operatör onayı beklemesi. **(Kavram: Confidence Threshold & Human in the Loop)**

Bu föyün çıktısı **AI Fail-Safe Decision** → Evidence Pack **EP 03 + EP 15** başlığına oturur.